

Baseline Comparison — Web3Bugs Benchmark (9 Contests)

Dataset

9 cuộc thi kiểm toán từ bộ dữ liệu chuẩn Web3Bugs. GT bugs là H-severity bugs từ audit reports thực tế. **Tổng GT = 116 H-bugs** (theo MECAP evaluation scope).

Lưu ý về GT scope: GT count của MECAP có thể thấp hơn tổng H-bugs trong audit report vì một số bugs bị loại khỏi GT sau khi kiểm tra source code thực tế: auditor ghi sai tên function, bug nằm ở nhánh code khác không có trong repository hiện tại, hoặc source code contest không còn đầy đủ. Ví dụ: contest 30 (yAxis) — report có 10 H-bugs nhưng GT thực tế = 8 do 2 bugs không reproduce được trên source code hiện có. Để đảm bảo so sánh công bằng, **tất cả tools đều dùng cùng GT denominator của MECAP**.

Các Baseline Được Đánh Giá

Tool	Loại	Cơ chế tìm bug
Slither	Static Analysis	Biên dịch Solidity → SlithIR (SSA) → 90+ detectors chạy data-flow và control-flow analysis. Mỗi detector kiểm tra 1 pattern cố định (reentrancy, integer overflow, arbitrary-send...). Hoàn toàn rule-based, không có LLM, không có ngữ nghĩa kinh tế.
GPTScan	LLM + Static	2 phase: (1) LLM screening — 9 preset scenario types (price manipulation, flash loan, wrong-order, front-running...), hỏi LLM từng function "có phải bug type X không?"; (2) Static verification — data-flow analysis xác nhận property cụ thể nếu LLM đồng ý. Không có RAG, không có cross-contract reasoning, bị giới hạn bởi 9 scenarios định sẵn.
LLMSmartAudit-BA	LLM role-chain	Sequential role-based conversation chain (ChatDev-style): 5 phases, mỗi phase là hội thoại giữa 2 roles — (1) CEO ↔ Security Analyst: brainstorm ideas; (2) Security Analyst ↔ Solidity Expert: deep code review dựa trên ideas; (3) Solidity Expert ↔ Security Analyst: tổng hợp bugs; (4) Security Testing Engineer ↔ Solidity Expert: phân tích test failures; (5) Security Testing Engineer ↔ Solidity Expert: đề xuất fixes. Output của phase trước làm input cho phase sau. Không có dedup, không có RAG, không có HIST-INV.
Single-agent	LLM	Dùng đúng pipeline MECAP (HIST-INV, RAG, 3-round reasoning T1→T2→T3, multi-stage dedup), nhưng chỉ có 1 agent duy nhất: universal_analyst — không có domain specialization, không có swarm. Ablation study để đo đóng góp của swarm so với pipeline.
MECAP (Đề xuất)	LLM swarm	20+ specialized agents theo domain (numerics, state consistency, access control, DeFi economics, integration), mỗi agent có expert identity + mental model riêng. HIST-INV: inject invariant lịch sử từ Knowledge Graph. RAG: retrieve 3000+ past audit findings tương tự. 3-round reasoning (T1: independent discovery → T2: cross-agent synthesis → T3: adversarial challenge). Multi-stage dedup: hash-based + LLM semantic clustering.

Per-Contest Recall

Sắp xếp theo Recall của MECAP (giảm dần). **Tất cả tools dùng GT denominator của MECAP.**

Contest	Giao thức	GT	Slither	GPTScan	LLMSmartAudit-BA	Single-agent	MECAP
71	Insure Protocol	13	0.154	0.000	0.231	0.462	0.923
104	Joyn	9	0.000	0.000	0.889	0.556	0.889
30	yAxis	8	0.000	0.125	0.375	0.375	0.875
42	Mochi	13	0.000	0.077	0.692	0.385	0.846
35	Trident (Sushi)	17	0.000	0.000	0.294	0.235	0.824
61	Sublime Finance	11	0.000	0.000	0.273	0.455	0.818
5	Vader Protocol	24	0.083	0.167	0.500	0.542	0.750
83	Concur Finance	10	0.000	0.000	0.700	0.500	0.700
3	MarginSwap	11	0.000	0.000	0.636	0.455	0.636

Tổng Kết Toàn Cục

GT = 116 cho tất cả tools (MECAP standard). Cột Findings: Slither/GPTScan/BA = raw output; Single-agent và MECAP = sau dedup.

Phương pháp	TP	Findings	Precision	Recall	F1
Slither	4	1,554 (raw)	0.003	0.034	0.005
GPTScan	6	53 (raw)	0.113	0.052	0.071
LLMSmartAudit-BA	57	1,791 ¹ (raw)	0.032	0.491	0.060
Single-agent	51	424 (dedup)	0.120	0.440	0.189
MECAP (Đề xuất)	93	1,562 (dedup)	0.060	0.802	0.111

¹ BA findings raw: 332+347+133+254+284+129+144+110+58 = 1,791. Contest 83 dùng raw=110 (không dedup).

Per-Contest TP Detail

Contest	Giao thức	GT	TP (GPTScan)	TP (BA)	TP (MECAP)
71	Insure Protocol	13	0	3	12
104	Joyn	9	0	8	8
30	yAxis	8	1	3	7
42	Mochi	13	1	9	11
35	Trident (Sushi)	17	0	5	14
61	Sublime Finance	11	0	3	9
5	Vader Protocol	24	4	12	18
83	Concur Finance	10	0	7	7
3	MarginSwap	11	0	7	7
Tổng		116	6	57	93

GPTScan — Chi Tiết Per-Contest

Contest	TP	FP	Findings	Precision	Recall	F1	TP bugs
3	0	5	5	0.000	0.000	0.000	—
5	4	20	24	0.167	0.167	0.167	H-02, H-05, H-08, H-12
30	1	2	3	0.333	0.125	0.182	H-05
35	0	0	0	—	0.000	0.000	—
42	1	2	3	0.333	0.077	0.125	
61	0	5	5	0.000	0.000	0.000	—
71	0	8	8	0.000	0.000	0.000	—
83	0	5	5	0.000	0.000	0.000	—
104	0	0	0	—	0.000	0.000	—

Nguồn: benchmark/web3bugs/gptscan//eval_result_manual.txt

LLMSmartAudit-BA — Chi Tiết Per-Contest

Raw findings = tổng findings trước dedup (BA không có dedup). Recall và Precision đều tính theo MECAP GT.

Contest	TP	Raw F inding s	Precision	Recall	F1	TP bugs
3	7	332	0.021	0.636	0.041	H-03,05,07,08,09,10,11
5	12	347	0.035	0.500	0.065	H-01,02,05,06,07,09,14,16,17,20,21,22
30	3	133	0.023	0.375	0.042	H-05,09,10
35	5	254	0.020	0.294	0.037	H-02,06,10,11,13
42	9	284	0.032	0.692	0.061	H-01,02,03,05,06,09,11,12,13
61	3	129	0.023	0.273	0.043	H-09,10,11
71	3	144	0.021	0.231	0.038	H-02,06,09
83	7	110	0.064	0.700	0.115	H-01,02,03,05,06,07,11
104	8	58	0.138	0.889	0.237	H-02,03,04,05,06,07,08,09

Nguồn: benchmark/web3bugs/llmsmartaudit-ba//eval_result_manual.txt

Quan Sát Chính

Về Recall:

- MECAP đạt Recall=0.802 — cao nhất, dẫn đầu ở 8/9 contests (đồng hạng với BA ở contest 104).

- LLMSmartAudit-BA đứng thứ hai (Recall=0.491), đặc biệt mạnh ở contests đơn giản (104: 0.889, 83: 0.700).
- Single-agent (0.440) và BA (0.491) gần nhau về recall tổng thể.
- GPTScan Recall thấp (0.052) — bị giới hạn bởi 9 preset scenario types; 5/9 contests TP=0.
- Slither Recall=0.034 — chỉ bắt được lỗi cấu trúc bề mặt.

Về Precision:

- Single-agent và GPTScan có precision cao nhất (0.120 và 0.113) — ít findings, mỗi finding có chất lượng hơn.
- MECAP (0.060) và BA (0.032) chấp nhận precision thấp để đổi lấy recall cao.
- Slither precision thấp nhất (0.003) với 1,554 findings gần như toàn FP.

Về F1:

- Single-agent F1 cao nhất (0.189) — cân bằng tốt nhất giữa precision và recall.
- MECAP F1=0.111, BA F1=0.060 — cả hai ưu tiên recall.
- Trong bài toán security audit, FN (bỏ sót bug) có chi phí cao hơn FP → **Recall là metric quan trọng hơn F1.**

Tóm tắt:

Metric	Tốt nhất	Xấu nhất
Recall	MECAP (0.802)	Slither (0.034)
Precision	Single-agent (0.120)	Slither (0.003)
F1	Single-agent (0.189)	Slither (0.005)
TP tuyệt đối	MECAP (93/116)	Slither (4/116)